SQL Para Data Science

Exercício Cenário de Análise de Dados 4

Este exercício é praticamente um projeto e poderá ser um pouco desafiador, pois, vamos unir todo o conhecimento abordado no curso até aqui. Siga as instruções abaixo com bastante atenção.

1- Download dos dados

Vamos trabalhar com dados reais disponíveis publicamente. Acesse o link abaixo para fazer o download dos arquivos (será necessário criar sua conta gratuita no Kaggle). Baixe todos os arquivos csv.

https://www.kaggle.com/nosbielcs/brazilian-delivery-center

2- Leia a descrição dos dados

O link acima, além dos dados para download, contém a descrição dos dados e detalhes sobre o cenário em que os dados foram extraídos. Leia com atenção para compreender o que cada dataset representa. O texto está em português.

3- Carregue os dados no banco de dados

Você pode usar o **Table Import Wizard** (que foi mostrado na solução do exercício 3) e importar os dados no MySQL. Crie uma tabela para cada arquivo (pode usar o nome da tabela como o mesmo nome de cada arquivo). A carga de dados deve funcionar sem problemas. **Mas há alguns detalhes**:

- Alguns arquivos têm milhões de registros e o tempo de carga pode ser bem alto dependendo do seu computador. Seja paciente e aguarde cada arquivo ser carregado. A lentidão é causada pelo MySQL Workbench. Caso queira acelerar o processo faça a carga via linha de comando conforme mostrado na solução do exercício 3.

- Um dos arquivos, o arquivo **hubs.csv**, tem texto com caracteres especiais e você terá problemas pelo MySQL Workbench. Adotamos como solução simples, editar o arquivo com um editor de texto (usamos o Sublime Text) e alteramos todas as linhas de SÃO PAULO para SAO PAULO (sem acento). Isso resolve o problema e os dados podem ser carregados sem dificuldade.

- O arquivo **deliveries.csv** pode apresentar erro de carga em um dos IDs de driver. Não há problema e é só ignorar. Mas se quiser corrigir, abra o arquivo em um editor de texto, busque por duas vírgulas juntas e substitua por isso: ,NULL,

Após carregar todos os arquivos seu ambiente deve ser parecer com a imagem abaixo.

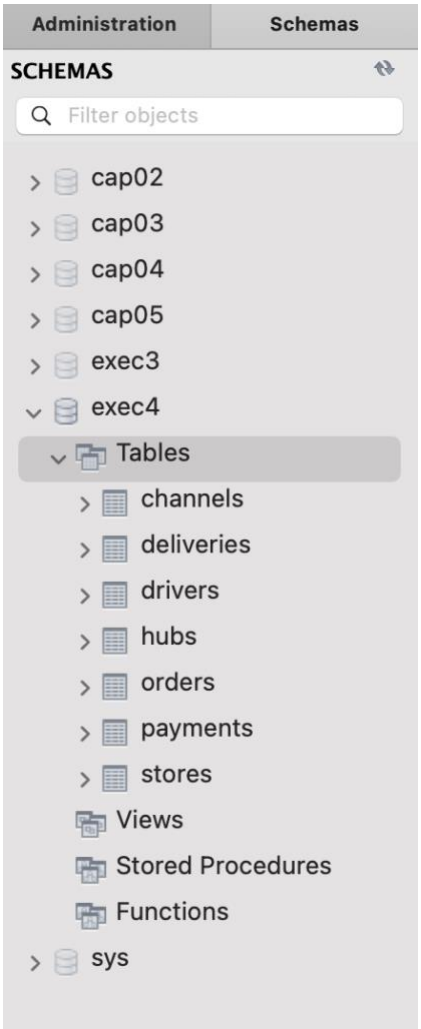

Trabalhar com dados reais não é fácil, mas o resultado é um aprendizado valioso.

Agora você estará pronto para criar suas queries SQL que respondam às perguntas abaixo. A solução será apresentada no começo do próximo capítulo. Bom trabalho.

1- Qual o número de hubs por cidade?

2- Qual o número de pedidos (orders) por status?

3- Qual o número de lojas (stores) por cidade dos hubs?

4- Qual o maior e o menor valor de pagamento (payment_amount) registrado?

5- Qual tipo de driver (driver_type) fez o maior número de entregas?

6- Qual a distância média das entregas por tipo de driver (driver_modal)?

7- Qual a média de valor de pedido (order_amount) por loja, em ordem decrescente?

8- Existem pedidos que não estão associados a lojas? Se caso positivo, quantos?

9- Qual o valor total de pedido (order_amount) no channel 'FOOD PLACE'?

10- Quantos pagamentos foram cancelados (chargeback)?

11- Qual foi o valor médio dos pagamentos cancelados (chargeback)?

12- Qual a média do valor de pagamento por método de pagamento (payment_method) em ordem decrescente?

13- Quais métodos de pagamento tiveram valor médio superior a 100?

14- Qual a média de valor de pedido (order_amount) por estado do hub (hub_state), segmento da loja (store_segment) e tipo de canal (channel_type)?

15- Qual estado do hub (hub_state), segmento da loja (store_segment) e tipo de canal (channel_type) teve média de valor de pedido (order_amount) maior que 450?

16- Qual o valor total de pedido (order_amount) por estado do hub (hub_state), segmento da loja (store_segment) e tipo de canal (channel_type)? Demonstre os totais intermediários e formate o resultado.

17- Quando o pedido era do Hub do Rio de Janeiro (hub_state), segmento de loja 'FOOD', tipo de canal Marketplace e foi cancelado, qual foi a média de valor do pedido (order_amount)?

18- Quando o pedido era do segmento de loja 'GOOD', tipo de canal Marketplace e foi cancelado, algum hub_state teve total de valor do pedido superior a 100.000?

19- Em que data houve a maior média de valor do pedido (order_amount)? Dica: Pesquise e use a função SUBSTRING().

20- Em quais datas o valor do pedido foi igual a zero (ou seja, não houve venda)? Dica: Use a função SUBSTRING().

Divirta-se. ☺